

مستندات پروژه Reinforcement Learning

محیط: LunarLander-v3

الگوریتم‌های پیاده‌سازی شده:

Q-Learning, SARSA, Approximate Q-Learning

محمد امین رضاپور

امیر محمد کمیجانی

فهرست مطالب

۱. معرفی پروژه و اهداف

۲. مفاهیم پایه Reinforcement Learning

۳. ساختار پروژه و فایل‌های کد

۴. الگوریتم‌های پیاده‌سازی شده

۵. نحوه اجرا و استفاده

۶. خروجی‌ها و نمودارها

۱. معرفی پروژه و اهداف

این پروژه یک پیاده‌سازی کامل از الگوریتم‌های یادگیری تقویتی (Reinforcement Learning) برای حل مسئله فرود سفینه فضایی بر روی ماه در محیط **LunarLander-v3** است. هدف اصلی این پروژه آموزش یک عامل هوشمند (Agent) است که بتواند سفینه فضایی را به‌صورت ایمن و با حداقل مصرف سوخت بر روی سطح ماه فرود آورد.

اهداف پروژه

- پیاده‌سازی سه الگوریتم اصلی Approximate Q-Learning و RL: Q-Learning، SARSA
 - آموزش عامل‌ها برای فرود ایمن سفینه فضایی
 - مقایسه عملکرد الگوریتم‌های مختلف از طریق نمودارها و متریک‌ها
 - ذخیره و بازیابی مدل‌های آموزش دیده برای استفاده مجدد

۲. مفاهیم پایه Reinforcement Learning

State (حالت)

در محیط LunarLander، هر حالت (State) یک بردار ۸ بعدی است که شامل اطلاعات زیر می‌باشد:

شاخص	توضیحات
0	موقعیت افقی (x-coordinate)
1	موقعیت عمودی (y-coordinate)
2	سرعت افقی (horizontal velocity)
3	سرعت عمودی (vertical velocity)
4	زاویه سفینه (angle)
5	سرعت زاویه‌ای (angular velocity)
6	پای چپ تماس با زمین (۰ یا ۱)
7	پای راست تماس با زمین (۰ یا ۱)

Action (عمل)

عامل می‌تواند یکی از ۴ عمل زیر را انتخاب کند:

Action	توضیحات
0	هیچ کاری انجام نده (Do Nothing)

1	موتور چپ را روشن کن (Fire Left Engine)
2	موتور اصلی را روشن کن (Fire Main Engine)
3	موتور راست را روشن کن (Fire Right Engine)

Reward (پاداش)

پاداش در هر مرحله بر اساس عملکرد سفینه محاسبه می‌شود:

- فرود موفق: پاداش بین ۱۰۰+ تا ۱۴۰+
- سقوط یا خروج از محدوده: پاداش منفی -۱۰۰
 - استفاده از موتور اصلی: جریمه -۰.۳
 - استفاده از موتورهای کناری: جریمه -۰.۰۳
 - هر پا که با زمین تماس داشته باشد: ۱۰+

۳. ساختار پروژه و فایل‌های کد

۳.۱ فایل `rlagents.py`

این فایل حاوی پیاده‌سازی تمامی الگوریتم‌های یادگیری تقویتی و توابع کمکی است. شامل:

کلاس‌ها و توابع اصلی:

- `Qtable`: کلاس دیکشنری سفارشی برای ذخیره مقادیر Q
- `Qlearning`: کلاس اصلی الگوریتم Q-Learning
- `SarsaQlearning`: کلاس الگوریتم SARSA (وارث `Qlearning`)
- `approximateQlearning`: کلاس الگوریتم Approximate Q-Learning
 - `discretize_state()`: تابع گسسته‌سازی حالت‌های پیوسته
 - `draw_2D_chart()` و `draw_3D_chart()`: توابع رسم نمودار
 - `load_qtable()` و `save_qtable()`: ذخیره و بارگذاری Q-table

۳.۲ فایل `main.py`

فایل اصلی برای اجرای پروژه. این فایل محیط را ایجاد کرده و الگوریتم مورد نظر را اجرا می‌کند.

```
env = gym.make("LunarLander-v3", render_mode="human") sarsaagent =  
SarsaQlearning(10000, flag=True) sarsaagent.train(env)
```

۳.۳ فایل `random_agent.py`

یک عامل ساده که به صورت تصادفی عمل انتخاب می‌کند. برای مقایسه با عامل‌های هوشمند استفاده می‌شود.

۴. الگوریتم‌های پیاده‌سازی شده

۴.۱ الگوریتم Q-Learning

Q-Learning یک الگوریتم یادگیری تقویتی off-policy است که بهینه‌ترین سیاست را بدون نیاز به مدل محیط یاد می‌گیرد.

فرمول به‌روزرسانی:

$$Q(s,a) \leftarrow Q(s,a) + \alpha[r + \gamma \max_{a'} Q(s',a') - Q(s,a)]$$

پارامترهای کلیدی:

- نرخ یادگیری α : ۰.۱ - تعیین می‌کند چقدر اطلاعات جدید جایگزین اطلاعات قدیمی شود
- ضریب تخفیف γ : ۰.۹۹ - اهمیت پاداش‌های آینده
- Epsilon (ϵ): کاهشی از ۱ به ۰ - احتمال انتخاب عمل تصادفی (exploration)

ویژگی‌های خاص:

- استفاده از Q-table برای ذخیره مقادیر Q برای هر جفت (state, action)
 - گسسته‌سازی فضای حالت پیوسته به حالت‌های گسسته
- استراتژی epsilon-greedy برای تعادل بین exploitation و exploration
 - به‌روزرسانی بر اساس بهترین عمل ممکن در حالت بعدی (off-policy)

۴.۲ الگوریتم SARSA

SARSA (State-Action-Reward-State-Action) یک الگوریتم on-policy است که سیاست فعلی را بهبود می‌بخشد.

فرمول به‌روزرسانی:

$$Q(s,a) \leftarrow Q(s,a) + \alpha[r + \gamma Q(s',a') - Q(s,a)]$$

تفاوت با Q-Learning:

- Q-Learning: از بهترین عمل ممکن (max) استفاده می کند - off-policy
 - SARSA: از عملی که واقعاً انتخاب شده استفاده می کند - on-policy
 - SARSA محافظه کارتر است و در محیط های خطرناک عملکرد بهتری دارد
- Q-Learning معمولاً سریع تر همگرا می شود اما ممکن است ریسک پذیرتر باشد

۴.۳ الگوریتم Approximate Q-Learning

این الگوریتم به جای ذخیره تمام مقادیر Q در یک جدول، از یک تقریب خطی استفاده می کند.

روش کار:

به جای ذخیره $Q(s,a)$ برای هر حالت، مقدار Q را به صورت زیر تقریب می زنند:

$$Q(s,a) = \sum w_i \times f_i(s) + w_0 \times a$$

مزایا:

- حافظه کمتر: فقط ۹ وزن به جای میلیون ها ورودی Q-table
- تعمیم بهتر: می تواند برای حالت های دیده نشده نیز پیش بینی کند
- عدم نیاز به گسسته سازی: مستقیماً با حالت های پیوسته کار می کند
 - همگرایی سریع تر در فضاهای حالت بزرگ

۵. نحوه اجرا و استفاده

۵.۱ نیازمندی‌های نصب

قبل از اجرای پروژه، کتابخانه‌های زیر را نصب کنید:

```
pip install gymnasium
pip install numpy
pip install matplotlib
pip install gymnasium[box2d]
```

۵.۲ حالت‌های مختلف اجرا

حالت ۱: آموزش مدل جدید Q-Learning

```
env = gym.make("LunarLander-v3", render_mode="human") agent = Qlearning(10000) #
10000 اپیزود agent.train(env) env.close()
```

حالت ۲: آموزش مدل جدید SARSA

```
env = gym.make("LunarLander-v3", render_mode="human") sarsaagent =
SarsaQlearning(10000) sarsaagent.train(env) env.close()
```

حالت ۳: بارگذاری و استفاده از مدل ذخیره شده

```
env = gym.make("LunarLander-v3", render_mode="human") sarsaagent =
SarsaQlearning(1000, flag=True) # ادامه sarsaagent.train(env) # بارگذاری برای
env.close() آموزش یا ارزیابی
```

حالت ۴: آموزش Approximate Q-Learning

```
env = gym.make("LunarLander-v3", render_mode="human") appxagent =  
approximateQlearning(5000) appxagent.train(env) env.close()
```

حالت ۵: آموزش بدون نمایش گرافیکی (سریع تر)

```
env = gym.make("LunarLander-v3") # بدون render_mode agent = Qlearning(10000)  
agent.train(env) env.close()
```

حالت ۶: اجرای عامل تصادفی (Baseline)

```
python random_agent.py
```

۵.۳ پارامترهای قابل تنظیم

پارامتر	مقدار پیش فرض	توضیحات
niteration	10000	تعداد اپیزودهای آموزش
alpha (α)	0.1	نرخ یادگیری
gamma (γ)	0.99	ضریب تخفیف
epsilon (ϵ)	کا هشی	احتمال exploration
flag	False	True برای بارگذاری مدل ذخیره شده
render_mode	human	نمایش گرافیکی یا None

۵.۴ فرایند اجرا گام به گام

۱. ایجاد محیط: محیط LunarLander با تنظیمات مورد نظر ایجاد می شود
۲. ساخت عامل: یکی از کلاس های Qlearning، SarsaQlearning یا approximateQlearning نمونه سازی می شود
۳. شروع آموزش: متد train() فراخوانی می شود و حلقه آموزش شروع می گردد
۴. در هر اپیزود: عامل حالت را مشاهده کرده، عمل انتخاب می کند، پاداش دریافت کرده و Q-values را به روز می کند
۵. نمایش پیشرفت: هر ۱۰۰ اپیزود، شماره iteration چاپ می شود
۶. ذخیره نتایج: پس از اتمام، نمودارها رسم و ذخیره می شوند
۷. بستن محیط: محیط شبیه سازی بسته می شود

۶. خروجی‌ها و نمودارها

۶.۱ خروجی‌های کنسول

در طول اجرا، اطلاعات زیر در کنسول نمایش داده می‌شود:

- پاداش کل هر اپیزود (Total Reward): پس از پایان هر اپیزود
 - شماره اپیزود: هر ۱۰۰ اپیزود یک بار
- پیام ذخیره‌سازی: پس از ذخیره Q-table یا وزن‌ها

۶.۲ فایل‌های خروجی

فایل	توضیحات
SavedQtable.txt	Q-table ذخیره شده برای Q-Learning و SARSA
SavedApproximateWeights.txt	وزن‌های ذخیره شده برای Approximate Q-Learning
QLearning_3D_chart.png	نمودار سه‌بعدی Q-Learning
QLearning_2D_chart.png	نمودار دوبعدی Q-Learning
SarsaQLearning_3D_chart.png	نمودار سه‌بعدی SARSA
SarsaQLearning_2D_chart.png	نمودار دوبعدی SARSA

۶.۳ نمودارها

نمودار دوبعدی (2D Chart)

- محور افقی (X): زمان (شماره اپیزود)
- محور عمودی (Y): پاداش کل دریافتی در هر اپیزود
- کاربرد: نمایش روند بهبود عملکرد عامل در طول زمان

نمودار سه‌بعدی (3D Chart)

- محور X: زمان (شماره اپیزود)
- محور Y: پاداش کل
- محور Z: آخرین عمل انتخاب شده
- کاربرد: بررسی رابطه بین زمان، پاداش و اعمال انتخاب شده

۶.۴ تفسیر نتایج

نحوه ارزیابی عملکرد الگوریتم‌ها:

- پاداش مثبت و رو به رشد: نشان‌دهنده یادگیری موفق
 - پاداش بالاتر از ۲۰۰: فرود بسیار موفق و بهینه
- کاهش نوسانات در نمودار: نشان‌دهنده ثبات در سیاست یادگرفته شده
 - پاداش منفی مداوم: عدم یادگیری یا نیاز به تنظیم پارامترها

۷. جزئیات فنی پیاده‌سازی

۷.۱ گسسته‌سازی فضای حالت

چون Q-Learning و SARSA نیاز به فضای حالت گسسته دارند، تابع `discretize_state` هر مؤلفه را به بازه‌های گسسته تبدیل می‌کند:

```
discrete_state = ( min(2, max(-2, int((state[0]) / 0.05))), min(2, max(-2,
int((state[1]) / 0.1))), ... int(state[6]), int(state[7]) )
```

- مقادیر پیوسته به بازه‌های گسسته $[-2, 2]$ تقسیم می‌شوند
- ضرایب تقسیم $(0.05, 0.1)$ برای کنترل دقت انتخاب شده‌اند

۷.۲ استراتژی Epsilon-Greedy

برای تعادل بین Exploration و Exploitation:

```
epsilon = (niteration - iternumber) / niteration if flipcoin(epsilon): action =
random.choice(actions) else: action = best_action
```

- در ابتدای آموزش: epsilon بالا → بیشتر Explore می‌کند
- در انتهای آموزش: epsilon پایین → بیشتر Exploit می‌کند

۷.۳ ذخیره‌سازی و بارگذاری مدل

برای استفاده مجدد از مدل‌های آموزش دیده:

- Q-table و وزن‌ها در فایل‌های متنی ذخیره می‌شوند
- با تنظیم `flag=True` در `constructor`، مدل قبلی بارگذاری می‌شود
- امکان ادامه آموزش یا استفاده برای ارزیابی فراهم است

۸. مقایسه الگوریتم‌ها

ویژگی	Q-Learning	SARSA	Approximate
نوع	Off-Policy	On-Policy	Off-Policy
حافظه	بالا (Q-table)	بالا (Q-table)	کم (۹ وزن)
سرعت همگرایی	متوسط	کند	سریع
تعمیم	ضعیف	ضعیف	عالی
ریسک‌پذیری	بالا	پایین	متوسط
دقت	بالا (با گسسته‌سازی)	بالا (با گسسته‌سازی)	متوسط
مناسب برای	فضای کوچک	محیط خطرناک	فضای بزرگ

نتیجه‌گیری

انتخاب الگوریتم بستگی به نیازهای پروژه دارد:

- برای محیط‌های خطرناک و نیاز به امنیت بیشتر: SARSA
- برای بهینه‌سازی سریع و فضای کوچک: Q-Learning
- برای فضاهای بزرگ و نیاز به تعمیم: Approximate Q-Learning

۹. رفع مشکلات متداول

مشکل ۱: محیط اجرا نمی‌شود

- راه‌حل: نصب کتابخانه Box2D با دستور `pip install gymnasium[box2d]`

مشکل ۲: عامل یاد نمی‌گیرد

- افزایش تعداد اپیزودها (niteration) را به ۲۰۰۰۰ یا بیشتر تغییر دهید)
- تنظیم نرخ یادگیری alpha (مقادیر بین ۰.۰۵ تا ۰.۳ را امتحان کنید)
- بررسی گسسته‌سازی (ضرایب تقسیم را تغییر دهید)

مشکل ۳: خطای حافظه

- استفاده از Approximate Q-Learning به جای Q-Learning/SARSA
- افزایش ضرایب گسسته‌سازی برای کاهش تعداد حالت‌ها

مشکل ۴: نمودارها ذخیره نمی‌شوند

- اطمینان از نصب matplotlib
- بررسی دسترسی نوشتن در پوشه اجرا

مشکل ۵: اجرا بسیار کند است

- حذف `render_mode="human"` برای افزایش سرعت

- کاهش تعداد اپیزودها برای تست اولیه
- استفاده از Approximate Q-Learning که معمولاً سریع‌تر همگرا می‌شود

۱۰. خلاصه و جمع‌بندی

این پروژه یک پیاده‌سازی کامل و جامع از الگوریتم‌های یادگیری تقویتی است که شامل موارد زیر می‌باشد:

- سه الگوریتم اصلی: SARSA (On-Policy)، Q-Learning (Off-Policy)، و Approximate Q-Learning (Function Approximation)
 - پیاده‌سازی کامل مفاهیم: State، Action، Reward، Q-Value، Policy
 - قابلیت ذخیره و بارگذاری مدل‌های آموزش دیده
 - تولید نمودارهای دوبعدی و سه‌بعدی برای تحلیل عملکرد
 - حالت‌های مختلف اجرا برای آموزش، ارزیابی و مقایسه

نکات کلیدی برای موفقیت

۸. صبور باشید: یادگیری تقویتی زمان‌بر است و ممکن است هزاران اپیزود طول بکشد
۹. پارامترها را تنظیم کنید: α ، γ و ϵ تأثیر زیادی بر سرعت و کیفیت یادگیری دارند
۱۰. الگوریتم مناسب را انتخاب کنید: بسته به محدودیت‌های حافظه، سرعت و دقت مورد نیاز
۱۱. از نمودارها استفاده کنید: برای درک بهتر روند یادگیری و شناسایی مشکلات
۱۲. مدل‌ها را ذخیره کنید: برای استفاده مجدد و جلوگیری از اتلاف زمان آموزش

پایان مستندات

موفق باشید!